Sistema RAG en Google Colab

MAESTRÍA EN DATA SCIENCE – PROYECTO FINAL

Curso: IA Generativa I

Integrantes:

- Ana Carbajal Fernández
- Renato Cipriano Chudán

Desafío: Documentos Técnicos Extensos

Contexto de la Tesis

Análisis de **334,018 caracteres** sobre "Entrainment of Fine Particles in Froth Flotation" (Queensland, 2016).

- **Alucinaciones Críticas:** Modelos base inventan datos en contextos mineros.
- **Límites de Contexto:** Imposible inyectar el PDF completo en el Prompt.
- **Necesidad de Grounding:** Precisión académica obligatoria para la toma de decisiones.

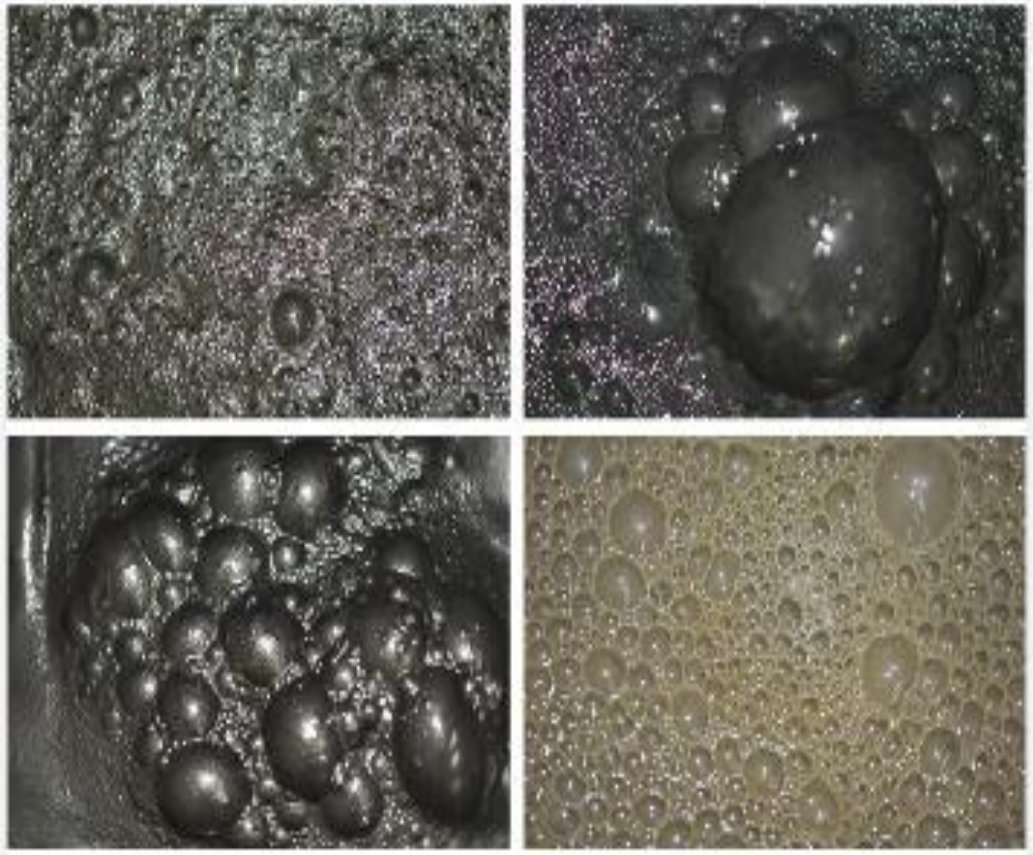

Arquitectura y Pipeline de Implementación

Flujo completo del sistema diseñado para procesar y recuperar información técnica:

Infraestructura

Google Colab + Hugging Face Transformers. Utilización de GPU para acelerar la vectorización de los 723 fragmentos generados.

Stack Tecnológico

Embedder: all-MiniLM-L6-v2
Vector Store: FAISS con HNSW
Generador: Flan-T5 Large (Seq2Seq)

Flujo de 8 etapas

1. **PDF Ingestion:** PyPDF2 para extracción.
2. **Chunking Semántico:** Segmentación dinámica.
3. **Embeddings:** all-MiniLM-L6-v2.
4. **Indexing:** FAISS con algoritmo HNSW.
5. **Retrieval:** k=5 vecinos cercanos.
6. **Reranking:** Refinamiento Cross-Encoder.
7. **Generación:** Flan-T5 Large.
8. **Auditoría:** Grounding Score & Citations.

Estrategia de Chunking: El Tradeoff Semántico

Justificación de Parámetros

Selección de **512 caracteres** y **50 overlap** (~10%) para balancear precisión y contexto.

Tamaño Chunk	Ventaja	Desventaja
Pequeño (256)	Alta precisión	Pérdida de contexto global
Medio (512)	**Balance Óptimo**	**Fragmentación moderada**
Grande (1024)	Contexto completo	Riesgo de ruido (Embedding Dilution)

Bibliografía Resumida:

Lewis et al. (2020): RAG mejora precisión dividiendo documentos en pasajes intermedios.

Izacard & Grave (2021): La granularidad afecta directamente la calidad de respuestas en QA.

LangChain (2023): Recomienda chunks de 256-512 tokens con overlap del 10-20%.

Resultado: Se generaron 723 fragmentos, superando el requisito de 100 documentos.

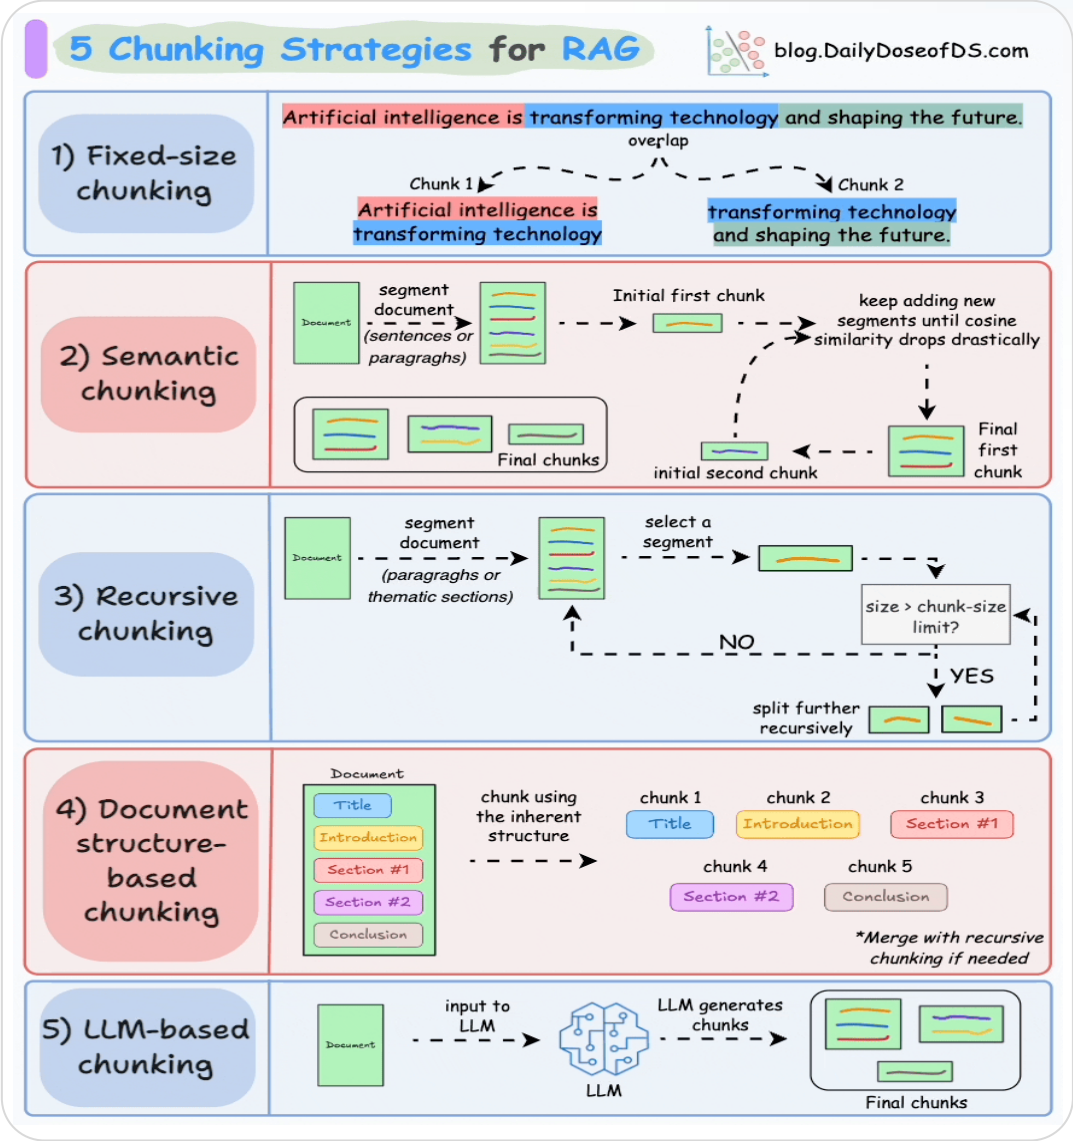

FAISS + HNSW: Búsqueda y Optimización

Proceso de Optimización

Se utilizó el **Chunk 320** como query inicial. La investigación permitió optimizar el sistema mediante un umbral de distancia.

Criterio de Relevancia:
Valores `dist < 0.5` representan alta similitud semántica.

Mantenimiento de Contexto: Se recuperan fragmentos técnicamente coherentes.

Filtrado de Ruido: Se evita información irrelevante que degrada la respuesta del LLM.

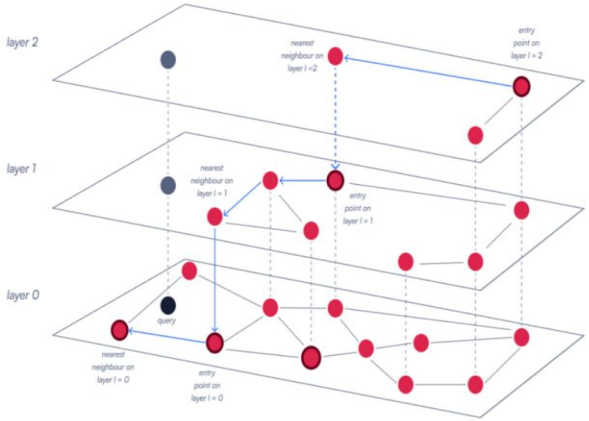


```
# Búsqueda Filtrada (dist < 0.5)

Chunk 320 → Distancia 0.0
...estimation of entrainment flow to the indirect estimation using water
recovery...
------
Chunk 2 → Distancia 0.326
...impeller speed and reagent dosage. Models incorporating different
factors...
------
Chunk 122 → Distancia 0.361
...pinning the effects of identified variables to enable better
models...
------
Chunk 114 → Distancia 0.374
...particles drain relative to water in the froth and state of
suspension...
------
Chunk 3 → Distancia 0.429
...significant barriers to be overcome before routine estimation in
industrial...
------
Chunk 377 → Distancia 0.440
Chunk 642 → Distancia 0.444
Chunk 115 → Distancia 0.446
Chunk 444 → Distancia 0.476
```

Los 10 vecinos recuperados se encuentran bajo el umbral óptimo de 0.5.

Reranker Cross-Encoder

Precisión de reordenamiento

FAISS recupera por similitud de embeddings, pero el **Cross-Encoder** evalúa la relación Query + Documento de forma conjunta.

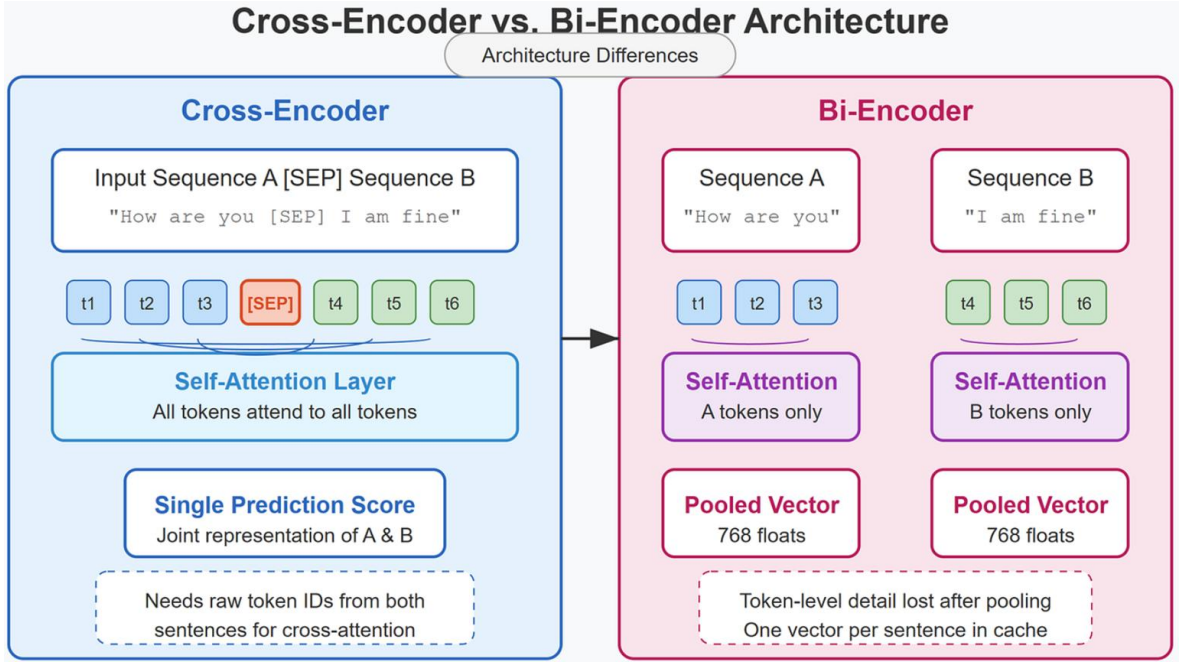

Modelo: ms-marco-MiniLM-L-6-v2. Elimina falsos positivos semánticos, garantizando el contexto más relevante asignándole un score de relevancia.

```
# Resultados Re-ordenados (Scores)

Chunk 320 → Score: 0.999
Chunk 2 → Score: 0.997
Chunk 114 → Score: 0.993
Chunk 122 → Score: 0.988
Chunk 3 → Score: 0.977

Los scores cercanos a 1.0 validan que el sistema identifica correctamente los
vecinos semánticos críticos para la tesis técnica.
```

En los resultados obtenidos, los fragmentos relacionados con “Modelos de arrastre en flotación” obtuvieron score superiores a 0.97, demostrando que el reranker mejora la precisión del sistema RAG al garantizar que el LLM reciba el contexto más relevante.

Módulos de Veracidad y Confianza

Citation per Sentence

¿Qué hizo?: Implementó un post-procesamiento que compara cada oración generada contra los chunks para asignar un ID de fuente explícito.

Justificación: En investigación de maestría, una IA de "caja negra" no es válida. Se requiere probar el origen de cada afirmación.

Ventaja: Trazabilidad vinculando cada frase al ID del Chunk fuente.

```
"...drain relative to water in the froth" [Fuente: Chunk 114]
```

Hallucination Guard + Grounding

¿Qué hizo?: Cuantificó la fidelidad semántica (0-1). Se estableció un umbral estricto de seguridad de 0.5 para invalidar invenciones.

Justificación: Evita que el modelo invente datos mineros que parecen coherentes pero no están en la tesis real.

Ventaja: Integridad científica.

```
Grounding Score: 0.98 ✓ Confiable
```

Resultados Colab:

Variante 1: "...particles drain relative to water in the froth"
[Fuente: Chunk 114] - Score: 0.98 ✓ Trazable

Variante 2: "...models have been developed to estimate entrainment"
[Fuente: Chunk 2] - Score: 0.99 ✓ Trazable

Resultados: Respuestas fundamentadas (scores 0.98 y 0.99) vs. descartes automáticos de alucinación (scores < 0.5).

Demo: Evaluación Comparativa de LLMs

Prueba de respuesta para la pregunta: *"What are entrainment models in flotation?"*

Flan-T5 Large (Elegido)

Ventaja: Modelo instructivo seq2seq. Aprovecha el contexto proporcionado en el prompt.

Resultado: Produjo respuestas técnicas coherentes alineadas con la tesis doctoral.

0.99 Grounded

Respuestas técnicas sin invención.

GPT-2 (Descartado)

Desventaja: Modelo de generación libre. No diseñado para seguir instrucciones estrictas.

Resultado: Secuencias incoherentes o inventadas con alta tasa de alucinación.

0.40 -0.55 Grounded

Presencia detectada de alucinaciones.

```
Grounding Score: 0.98 ✓ Confiable
```

```
Código Colab (GPT-2)
Grounding score: 0.5837
Q: What are entrainment models? [⚠ Alucinación]
Ans: The particles drain in water... [✓ Fundamentado]
Ans: Developed by International Water Recovery Society (IHRS). [⚠ Alucinación]

* El sistema detectó que GPT-2 inventó una sociedad inexistente (IHRS) fuera de la tesis.
```

Conclusión Demo: La migración a modelos instructivos es crítica para sistemas RAG técnicos.

Análisis de Resultados y Métricas

BLEU (Bilingual Evaluation Understudy)

- Mide coincidencia léxica exacta (n-gramas) entre la respuesta generada y los chunks de referencia
- Divide la respuesta en tokens (palabras)
- **Óptimo:** >0.7-0.8 (indica alta similitud de palabras con las referencias).

ROUGE-L (Recall-Oriented Understudy for Gisting Evaluation

- Mide el recall (cobertura) del contenido original. % del contenido de referencias aparece en la respuesta.
- **Óptimo:** Valores moderados (~0.5). indica que la respuesta captura parte del contenido, pero no todo el texto literal.

Grounding Score

- Mide similitud semántica profunda (coseno) entre la respuesta y los embedding de los chunks.
- Convierte la respuesta y los chunks en vectores de significado.
- **Óptimo:** > 0.7 - 0.8 (garantiza veracidad científica) y < 0.5 se considera posible alucinación.

```
# Evaluación de Variantes (Terminal)

=== Variante 1 ===
Oración: representing the degree to which entrained particles drain relative to water in
the froth

BLEU: 0.92 | ROUGE-L: 0.50 | Grounding: 0.98

=== Variante 2 ===
Oración: A number of models incorporating different factors have been developed to
estimate entrainment recovery

BLEU: 0.92 | ROUGE-L: 0.50 | Grounding: 0.99

* El BLEU de 0.92 indica fidelidad absoluta, mientras que el ROUGE valida una sintesis técnica experta.
```

Interpretación de Resultados:

- **BLEU Alto (0.92):** Las respuestas son extremadamente fieles a las frases originales de la tesis.
- **ROUGE Moderado (0.50):** Positivo; el modelo no solo "copia y pega", sino que **sintetiza y reformula** con fidelidad técnica.
- **Grounding Máximo (0.98-0.99):** Confirmación de que el sistema no alucina y está 100% fundamentado.

Conclusión: El sistema RAG autoevaluado garantiza trazabilidad técnica y confiabilidad académica absoluta.

Búsqueda Híbrida: BM25 + FAISS

¿Qué es Hybrid Search?

Es la fusión de dos mundos: la **precisión léxica** (BM25) y la **comprensión semántica** (FAISS). Este enfoque garantiza que no se pierdan términos técnicos clave ni relaciones conceptuales profundas.

Mecanismo de Fusión

- **BM25:** Modelo clásico de recuperación de información basado en conteo de palabras y su frecuencia. Captura coincidencias léxicas exactas ("entrainment", "flotation").
- **FAISS:** Motor de búsqueda vectorial. Usa los embedding para medir similitud semántica Encuentra pasajes relevantes por contexto latente.
- **Ranking:** Se promedian o ponderan los scores para generar una lista final robusta para el LLM (Flan-T5 Large).

Resultados Obtenidos

Chunk ID	BM25	FAISS	Hybrid
320	0.07	0.48	0.27
2	**0.58**	**0.48**	**0.53**
114	**0.51**	**0.49**	**0.50**

** Los Chunks 2 y 114 demostraron el mejor balance léxico-semántico.*

Interpretación:
BM25 captó palabras clave técnicas cruciales, mientras que FAISS validó la relevancia conceptual. La fusión híbrida confirmó que estos fragmentos son los más aptos para generar respuestas trazables y confiables.

Ventaja Competitiva: Ranking más robusto que previene la pérdida de coincidencias literales importantes.

Conclusiones del Proyecto

Integridad y Audibilidad

La implementación de **Citation per Sentence** elimina la opacidad de los LLMs. Convertir la IA de una "caja negra" a un sistema auditable es fundamental para el análisis científico de un documento técnico.

Escalabilidad y Eficiencia

El algoritmo **HNSW** demostró ser la infraestructura ideal para indexación. Permite escalar de 723 fragmentos a millones de documentos manteniendo latencias mínimas en Google Colab.

Veracidad cuantificable

Un **Grounding Score de 0.99** y un **BLEU de 0.92** validan que el sistema no solo recupera, sino que sintetiza con fidelidad absoluta, erradicando el riesgo de alucinaciones técnicas principalmente en documentos de carácter técnico.

Sinergia técnica

La combinación de **Búsqueda Híbrida (BM25 + FAISS)** y **Reranking** es el paso crítico para una RAG profesional. Garantiza que términos técnicos clave nunca se pierdan en la vectorización.
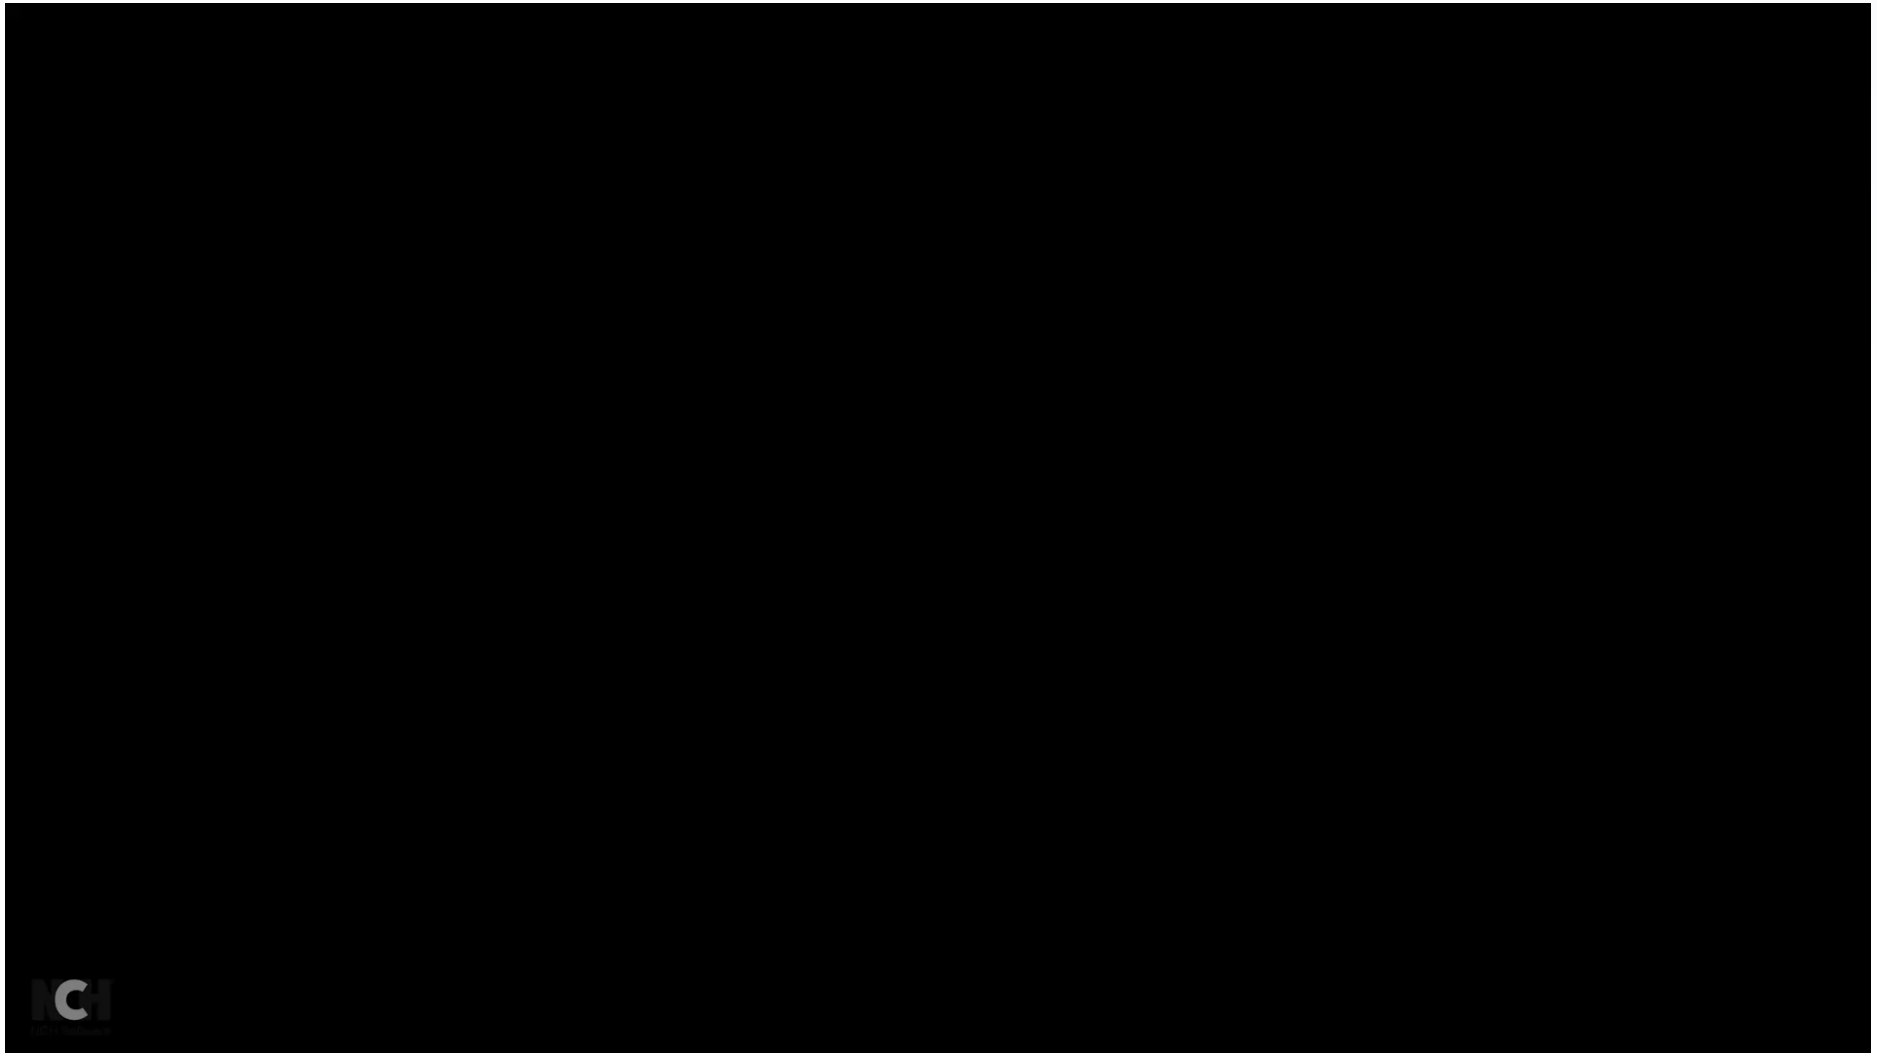
Video – Colab